

3η Σειρά Ασκήσεων

Ομάδα:

Άγγελος Τσελές (Α.Μ: 3170160)

Ανδρέας Πολυχρονάκης (Α.Μ: 3170140)

Άσκηση 1

a)

Για να είναι ακριβές το διάστημα εμπιστοσύνης θα πρέπει:

- 1) Τα δεδομένα να προέρχονται από απλό τυχαίο δείγμα
- 2) $X=29 \geq 15$ και $n-X=50-29=21 > 15$ όπου X =πλήθος κορωνών και n =πλήθος συνολικών ρίψεων

Άρα τα δεδομένα είναι κατάλληλα για τον υπολογισμό του διαστήματος εμπιστοσύνης.

Για $c=95\%$ $z=\text{abs}(qnorm(0.025))=1.96$

Δειγματικό ποσοστό $p = X/n = 29/50 = 0.58$

Έστω $m = z * \sqrt{p*(1-p)/n} = 1.96 * \sqrt{0.58*0.42/50} = 0.1368$

$\max = p+m = 0.58+0.1368 = 0.7168$

$\min = p-m = 0.58-0.1368 = 0.4432$

Διάστημα Εμπιστοσύνης 95 % = $[\min, \max] = [44.32\% , 71.68\%]$

b)

Για να είναι ακριβής ο έλεγχος σημαντικότητας θα πρέπει:

- 1) Τα δεδομένα να προέρχονται από απλό τυχαίο δείγμα
- 2) $N * p_0 \geq 10 \Leftrightarrow 50 * 0.5 \geq 10$ ΙΣΧΥΕΙ
και $N * (1-p_0) \geq 10 \Leftrightarrow 50 * 0.5 \geq 10$ ΙΣΧΥΕΙ

Άρα τα δεδομένα είναι κατάλληλα για τον έλεγχο σημαντικότητας.

Μηδενική Υπόθεση H_0 : $p = 50\%$

Εναλλακτική Υπόθεση H_a : $p \neq 50\%$

Στατιστικό ελέγχου $z = (p-p_0)/\sqrt{(p_0*(1-p_0)/n)} = (0.58-0.5)/\sqrt{(0.5*0.5/50)} = 1.131$

3η Σειρά Ασκήσεων

$$p \text{ value} = 2 * \Phi(-|z|) = 2 * \text{pnorm}(-\text{abs}(z)) = 0.2578$$

Παρατηρούμε ότι $p \text{ value} > \alpha = 0.05$ οπότε δεν μπορούμε να απορρίψουμε την μηδενική υπόθεση σε επίπεδο σημαντικότητας 5%.

c)

Ψάχνω το n για $m=0.01$

$$\text{Έχω ότι } m = z * \sqrt{p*(1-p)/n}$$

$$\text{Άρα } n = p*(1-p) * (z/m)^2$$

$$\text{Για } p=0.58 : n = 0.58*0.42 * (1.96/0.01)^2 = 9357,1376 \text{ άρα } n = 9358 \text{ ρίψεις}$$

Άσκηση 2

Για Ελλάδα: $n = 10000000$, $X=1100$, $C=95\%$, $m = 0.03\%$

Για ΗΠΑ: $n = 300000000$, $X=;$, $C=95\%$, $m = 0.03\%$

Για $C=95\%$: $z=\text{abs}(qnorm(0.025))=1.96$

Με δεδομένα ότι $z = 1.96$ και $m = 0.03\%$ αρκεί ότι:

$$n \geq (z^2) / (4*(m^2)) \Leftrightarrow n \geq 1067.11$$

Άρα απαιτούνται τουλάχιστον 1068 άτομα για την πραγματοποίηση αντίστοιχων δημοσκοπήσεων στις Η.Π.Α. Παρατηρούμε ότι το μέγεθος δείγματος δεν εξαρτάται από τον πληθυσμό της χώρας που διεξάγεται η δημοσκόπηση.

Άσκηση 3

Τα δεδομένα είναι κατάλληλα για τους παρακάτω ελέγχους καθώς:

- 1) Προέρχονται από απλό τυχαίο δείγμα
- 2) Ο αριθμός των επιτυχιών και των αποτυχιών είναι μεγαλύτεροι από 15,όπως προκύπτει εύκολα παρατηρώντας τον πίνακα

3η Σειρά Ασκήσεων

a)

Μηδενική Υπόθεση H_0 : $p_1 = p_2$

Εναλλακτική Υπόθεση H_a : $p_1 \neq p_2$

Έστω p_1 = ποσοστό ανδρών που καπνίζουν και p_2 = ποσοστό γυναικών που καπνίζουν

$$p_1 = X_1 / n_1 = \text{sum}(\text{sex}=="M" \ \& \ \text{smoker}=="YES") / \text{sum}(\text{sex}=="M") = 12/30 = 0.4$$

$$p_2 = X_2 / n_2 = \text{sum}(\text{sex}=="F" \ \& \ \text{smoker}=="YES") / \text{sum}(\text{sex}=="F") = 14/30 = 0.4666$$

$$\text{Έχουμε ότι } p = (X_1+X_2) / (n_1+n_2) = 26/60 = 0.433333$$

$$\text{Στατιστικό } z = (p_1-p_2) / \sqrt{p*(1-p) * (1/n_1 + 1/n_2)} = -0.52105$$

$$\text{Επιπλέον έχουμε ότι } p \text{ value} = 2 * \Phi(-|z|) = 2 * \text{pnorm}(-\text{abs}(z)) = 0.60233$$

Παρατηρούμε ότι το p value είναι πολύ μεγάλο οπότε δεν απορρίπτουμε την μηδενική υπόθεση.

b)

Για $C=95\%$ διάστημα εμπιστοσύνης έχουμε ότι $z=\text{abs}(\text{qnorm}(0.025))=1.96$

$$\text{Έχουμε ότι } m = z * \sqrt{p_1*(1-p_1)/n_1 + p_2*(1-p_2)/n_2} = 0.25$$

$$\text{min} = p_2-p_1-m = 0.4666-0.4-0.25 = -0.1834$$

$$\text{max} = p_2-p_1+m = 0.4666-0.4+0.25 = 0.3166$$

$$\text{Άρα Διάστημα Εμπιστοσύνης } 95\% = [-0.1834, 0.3166]$$

c)

Μηδενική Υπόθεση H_0 : Τα ποσοστά του αρχικού δείγματος ταυτίζονται με του πίνακα E_{ij}

Εναλλακτική Υπόθεση H_a : Τα ποσοστά του αρχικού δείγματος δεν ταυτίζονται με του πίνακα E_{ij}

Από τον z έλεγχο στο αρχικό δείγμα (O_{ij}) έχουμε:

p_1 = ποσοστό ανδρών που καπνίζουν και p_2 = ποσοστό γυναικών που καπνίζουν

$$p_1 = 12 / 30 = 0.4$$

$$p_2 = 14 / 30 = 0.4666$$

3η Σειρά Ασκήσεων

```
> table(smoker, sex)
      sex
smoker F  M
NO     16 18
YES    14 12
```

Εικόνα 1: Πίνακας Oij

Για το χ^2 έλεγχο (E_{ij}) προκύπτουν τα εξής:

$$E_{ij} = O_i \cdot O_j / n$$

$$p1' = (30 * (12+14) / 60) / 30 = 13/30 = 0.43333$$

$$p2' = (30 * (12+14) / 60) / 30 = 13/30 = 0.43333$$

Εκτελούμε chi-squared test

```
> chisq.test(table(smoker, sex), correct=FALSE)
```

```
      Pearson's Chi-squared test
```

```
data:  table(smoker, sex)
X-squared = 0.27149, df = 1, p-value = 0.6023
```

Άρα προκύπτει ότι $X\text{-squared}=0.27149$, $df=1$ και $p\text{ value} = 0.6023$

Παρατηρούμε ότι το $p\text{ value}$ είναι πολύ μεγάλο οπότε δεν απορρίπτουμε την μηδενική υπόθεση

d)

Προκύπτει ότι $p\text{ value z ελέγχου} = 0.60233$ και $p\text{ value } \chi^2 \text{ ελέγχου} = 0.6023$

Τα δύο $p\text{ value}$ έχουν σχεδόν ακριβώς την ίδια τιμή διότι ο πίνακας των δεδομένων είναι 2×2 και συνεπώς οι βαθμοί ελευθερίας του χ^2 ελέγχου είναι $df = (2-1)(2-1) = 1$, δηλαδή ίδιοι με την κανονική κατανομή.

3η Σειρά Ασκήσεων

Άσκηση 4

Τα δεδομένα είναι κατάλληλα για τους παρακάτω ελέγχους διότι:

- 1) Προέρχονται από ένα απλό τυχαίο δείγμα(συσκευασία περιπτέρου)
- 2) Ο αριθμός επιτυχιών και αποτυχιών είναι μεγαλύτερος από 15

Από τα δεδομένα έχουμε:

$$X_{\text{Brown}} = 22$$

$$X_{\text{Red}} = 19$$

$$X_{\text{Yellow}} = 16$$

$$X_{\text{Blue}} = 15$$

$$X_{\text{Green}} = 8$$

$$\text{Sum} = 80$$

Άρα τα ποσοστά εμφάνισης κάθε χρώματος είναι:

$$p_{\text{brown}} = 22/80 = 0.275$$

$$p_{\text{red}} = 19/80 = 0.2375$$

$$p_{\text{yellow}} = 16/80 = 0.20$$

$$p_{\text{blue}} = 15/80 = 0.1875$$

$$p_{\text{green}} = 8/80 = 0.10$$

a)

Τα δεδομένα είναι κατάλληλα για τους παρακάτω ελέγχους διότι:

- 1) Προέρχονται από ένα απλό τυχαίο δείγμα(συσκευασία περιπτέρου)
- 2) $n \cdot p_0 \geq 10$ και $n \cdot (1-p_0) \geq 10$

Μηδενική Υπόθεση H_0 : $p_{\text{red}} = p_{\text{blue}}$

Εναλλακτική Υπόθεση H_a : $p_{\text{red}} > p_{\text{blue}}$

3η Σειρά Ασκήσεων

Κάνουμε z έλεγχο:

$$z = (p_{\text{red}} - p_{\text{blue}}) / \sqrt{p_{\text{blue}}(1-p_{\text{blue}})/n}$$

$$p \text{ value} = 1 - \Phi(z) = 0.1259423$$

Το p value είναι σχετικά μεγάλο οπότε η μηδενική υπόθεση δεν θα απορριφθεί.

b)

$$p_{\text{old_brown}} = 0.198 \Rightarrow X_{\text{old_Brown}} = 0.198 * 80 = 15.84$$

$$p_{\text{old_red}} = 0.178 \Rightarrow X_{\text{old_red}} = 0.178 * 80 = 14.24$$

$$p_{\text{old_yellow}} = 0.176 \Rightarrow X_{\text{old_yellow}} = 0.176 * 80 = 14.08$$

$$p_{\text{old_blue}} = 0.196 \Rightarrow X_{\text{old_blue}} = 0.196 * 80 = 15.68$$

$$p_{\text{old_green}} = 0.252 \Rightarrow X_{\text{old_green}} = 0.252 * 80 = 20.16$$

Μηδενική Υπόθεση H_0 : Δεν έχει αλλάξει η κατανομή

Εναλλακτική Υπόθεση H_a : Έχει αλλάξει η κατανομή

$$\text{Ισχύει ότι } \chi^2 = (O_{ij} - E_{ij})^2 / E_{ij}$$

$$x1 = (X_{\text{Brown}} - X_{\text{old_Brown}})^2 / X_{\text{old_Brown}} = (22 - 15.84)^2 / 15.84 = 2.3955$$

$$x2 = (X_{\text{Red}} - X_{\text{old_Red}})^2 / X_{\text{old_Red}} = (19 - 14.24)^2 / 14.24 = 1.5911$$

$$x3 = (X_{\text{Yellow}} - X_{\text{old_Yellow}})^2 / X_{\text{old_Yellow}} = (16 - 14.08)^2 / 14.08 = 0.2618$$

$$x4 = (X_{\text{Blue}} - X_{\text{old_Blue}})^2 / X_{\text{old_Blue}} = (15 - 15.68)^2 / 15.68 = 0.0294$$

$$x5 = (X_{\text{Green}} - X_{\text{old_Green}})^2 / X_{\text{old_Green}} = (8 - 20.16)^2 / 20.16 = 7.334$$

$$\text{Άρα } \chi^2 = x1 + x2 + x3 + x4 + x5 = 11.6118$$

$$df = 5 - 1 = 4$$

Άρα p value = 0.02 ,οπότε απορρίπτουμε την μηδενική υπόθεση. Η κατανομή έχει αλλάξει

3η Σειρά Ασκήσεων

c)

Μηδενική Υπόθεση H_0 : Η αναλογία χρωμάτων στα smarties είναι ίδια με αυτή στα M&Ms

Εναλλακτική Υπόθεση H_a : Η αναλογία χρωμάτων στα smarties δεν είναι ίδια με αυτή στα M&Ms

Από τα δεδομένα έχουμε:

$X_{MM_Brown} = 10$

$X_{MM_Red} = 12$

$X_{MM_Yellow} = 20$

$X_{MM_Blue} = 9$

$X_{MM_Green} = 5$

Sum = 56

Εκτελούμε chi-squared test με t1 τον πίνακα για τα M&Ms και t2 τον πίνακα για τα smarties.

```
> t1

  Blue Brown Green  Red Yellow
    9   10    5   12   20

> t2

  Blue Brown Green  Red Yellow
   15   22    8   19   16
> prop2 <- prop.table(t1)
> chisq.test(t2, p = c(prop2[1], prop2[2], prop2[3], prop2[4], prop2[5]))

      Chi-squared test for given probabilities

data:  t2
X-squared = 10.358, df = 4, p-value = 0.03481
```

Το p value = 0.03481 είναι πολύ μικρό, οπότε μπορούμε να απορρίψουμε την μηδενική υπόθεση